

NUMERICKÉ METÓDY LINEÁRNEJ ALGEBRY

05. Iteračné metódy riešenia lineárnych sústav.

Ing. Marek Macák, PhD.

Konzultácie: podľa potreby/dohody

5. Marec 2024

Iteračné metódy riešenia

- Výsledkom *iteračných metód*, nazývaných aj *nepriame metódy*, je *približné riešenie*, ktoré je zaťažené nielen zaokrúhľovacími chybami, ale aj chybami metódy. Od požadovanej presnosti potom závisí *počet krokov = iterácií*.
- Na začiatku vždy volíme *počiatočnú aproximáciu riešenia* $\mathbf{x}^{(0)}$, ktorú potom iteračným procesom spresňujeme.
- Výpočet iterácií zastavujeme *zastavovacou podmienkou*, ktorá najčastejšie býva formulovaná v tvare
 - a) veľkosť rozdielu riešenia dvoch po sebe idúcich iterácií, t. j. $\mathbf{r}^{(k)} = |\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}|$,
 $\|\mathbf{r}^{(k)}\| \leq \varepsilon$,
 - b) rezíduum poslednej iterácie, t. j. $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{Ax}^{(k)}$, $\|\mathbf{r}^{(k)}\| \leq \varepsilon$.
- Iteračné metódy *môžu aj divergovať*, závisí to od vlastností matice systému a samotnej iteračnej metódy, viac neskôr.

Iteračné metódy riešenia

- Princíp *Jacobiho metódy*¹ vysvetlíme na:

$$a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1,$$

$$a_{21}x_1 + a_{22}x_2 + a_{2n}x_3 = b_2,$$

$$a_{31}x_1 + a_{32}x_2 + a_{3n}x_3 = b_3.$$

Každú z rovníc vydelíme koeficientom a_{ii} za predpokladu, že $a_{ii} \neq 0$

$$x_1 + \frac{a_{12}}{a_{11}}x_2 + \frac{a_{13}}{a_{11}}x_3 = \frac{b_1}{a_{11}},$$

$$\frac{a_{21}}{a_{22}}x_1 + x_2 + \frac{a_{23}}{a_{22}}x_3 = \frac{b_2}{a_{22}},$$

$$\frac{a_{31}}{a_{33}}x_1 + \frac{a_{32}}{a_{33}}x_2 + x_3 = \frac{b_3}{a_{33}}.$$

¹Carl Gustav Jacob Jacobi (1804 - 1851) bol nemecký matematik, ktorý okrem iného významne prispel do teórie systémov ODR a PDR 1. rádu, a k rozvoju diferenciálnej geometrie.



Iteračné metódy riešenia

- Potom z prvej rovnice vyjadríme x_1 , z druhej rovnice vyjadríme x_2 , z tretej rovnice vyjadríme x_3 a zapíšme nasledovne

$$\begin{aligned}x_1 &= 0 \cdot x_1 - \frac{a_{12}}{a_{11}}x_2 - \frac{a_{13}}{a_{11}}x_3 + \frac{b_1}{a_{11}}, \\x_2 &= -\frac{a_{21}}{a_{22}}x_1 + 0 \cdot x_2 - \frac{a_{23}}{a_{22}}x_3 + \frac{b_2}{a_{22}}, \\x_3 &= -\frac{a_{31}}{a_{33}}x_1 - \frac{a_{32}}{a_{33}}x_2 + 0 \cdot x_3 + \frac{b_3}{a_{33}},\end{aligned}$$

respektíve v maticovom tvare

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} \\ -\frac{a_{31}}{a_{33}} & -\frac{a_{32}}{a_{33}} & 0 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + \begin{pmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \frac{b_3}{a_{33}} \end{pmatrix}.$$



Iteračné metódy riešenia

- Iteračná formula pre výpočet vektora $\mathbf{x}^{(k)}$, $k = 1, \dots$, bude potom mať tvar

$$x_1^{(k)} = 0 \cdot x_1^{(k-1)} - \frac{a_{12}}{a_{11}} x_2^{(k-1)} - \frac{a_{13}}{a_{11}} x_3^{(k-1)} + \frac{b_1}{a_{11}},$$

$$x_2^{(k)} = -\frac{a_{21}}{a_{22}} x_1^{(k-1)} + 0 \cdot x_2^{(k-1)} - \frac{a_{23}}{a_{22}} x_3^{(k-1)} + \frac{b_2}{a_{22}},$$

$$x_3^{(k)} = -\frac{a_{31}}{a_{33}} x_1^{(k-1)} - \frac{a_{32}}{a_{33}} x_2^{(k-1)} + 0 \cdot x_3^{(k-1)} + \frac{b_3}{a_{33}},$$

respektíve

$$\begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ x_3^{(k)} \end{pmatrix} = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} \\ -\frac{a_{31}}{a_{33}} & -\frac{a_{32}}{a_{33}} & 0 \end{pmatrix} \cdot \begin{pmatrix} x_1^{(k-1)} \\ x_2^{(k-1)} \\ x_3^{(k-1)} \end{pmatrix} + \begin{pmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \frac{b_3}{a_{33}} \end{pmatrix}.$$

Všeobecný algoritmus

- Úloha: nájsť riešenie sústavy lineárnych rovníc:

$$Ax = b, \quad A \in \mathbb{C}^{n \times n}, \quad x, b \in \mathbb{C}^{n \times 1}$$

- Všeobecný algoritmus iteračnej metódy:
 - Zvoľ počiatočnú aproximáciu $x^{(0)} \in \mathbb{C}^{n \times 1}$
 - Pre $k = 0, 1, 2, \dots$ opakuj až po konvergenciu

$$x^{(k)} = Bx^{(k-1)} + c, \tag{1}$$

kde B a c závisia od iteračnej metódy.

- Stacionárne iteračné metódy poznáme: *Jacobi*, *Gauss-Seidel*, *Successive Overrelaxation (SOR)* a *Symmetric Successive Overrelaxation (SSOR)*.

Rozklad matice A

- Základný rozklad matice A (nie faktorizácia):

$$A = D - L - U,$$

kde D je diagonála A , L je dolný trojuholník matice A (bez diagonály) a U je horný trojuholník matice A (bez diagonály).

- Iný typ rozkladu (tzv. 'splitting'):

$$A = M - N,$$

napr. $M = D$ a $N = -(L + U)$.



Jacobiho metóda

- Všeobecne *Jacobiho metódu* môžeme napísať nasledovne: Vyberme i -tu rovnicu

$$\sum_{j=1}^n a_{ij}x_j = b_i$$

riešime pre hodnotu x_i za predpokladu, že ostatné zložky x zostanú pevné, a dostaneme

$$x_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=1, i \neq j}^n a_{ij}x_j \right).$$

- To určuje iteračnej metóde definovanú pomocou

$$x_i^{(k)} = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=1, i \neq j}^n a_{ij}x_j^{(k-1)} \right).$$

(2)

Jacobiho metóda

- Jacobiho metóda je založená na riešení pre každú premennú lokálne vzhľadom na iné premenné.
- Jedna iterácia metódy zodpovedá riešeniu pre každú premennú raz.
- Výsledná metóda je ľahko pochopiteľná a implementovateľná, ale konvergencia je pomalá.
- V maticovom vyjadrení môže byť Jacobiho metóda vyjadrená ako:

$$x^{(k)} = D^{-1}(L + U)x^{(k-1)} + D^{-1}b. \quad (3)$$

kde $D^{-1}(L + U) = \mathbf{B}$ a $D^{-1}b = \mathbf{c}$



Jacobiho metóda

- **Príklad:** Jacobiho metódou nájdite riešenie sústavy lineárnych rovníc s presnosťou $|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}| < 0,1$:

$$4x_1 - 0,8x_2 - 0,5x_3 = 14,5$$

$$0,3x_1 + 17x_2 - 0,9x_3 = -19,3$$

$$0,85x_1 - 0,2x_2 + 7x_3 = 61,4$$

keď počiatočná aproximácia riešenia je $\mathbf{x}^{(0)} = (0; 0; 0)^T$.



Jacobiho metóda

- Riešenie: **Prvá iterácia:** Dosadíme $x_1^{(0)} = 0$, $x_2^{(0)} = 0$ a $x_3^{(0)} = 0$ do (1) a vyčíslime

$$x_1^{(1)} = 0 \cdot x_1^{(0)} - \frac{a_{12}}{a_{11}}x_2^{(0)} - \frac{a_{13}}{a_{11}}x_3^{(0)} + \frac{b_1}{a_{11}} = \frac{1}{4} \cdot 14,5 = 3,6250$$

$$x_2^{(1)} = -\frac{a_{21}}{a_{22}}x_1^{(0)} + 0 \cdot x_2^{(0)} - \frac{a_{23}}{a_{22}}x_3^{(0)} + \frac{b_2}{a_{22}} = \frac{1}{17} \cdot -19,3 = -1,1353$$

$$x_3^{(1)} = -\frac{a_{31}}{a_{33}}x_1^{(0)} - \frac{a_{32}}{a_{33}}x_2^{(0)} + 0 \cdot x_3^{(0)} + \frac{b_3}{a_{33}} = \frac{1}{7} \cdot 61,4 = 8,7714$$

Spočítame rozdiely medzi iteráciami

$$|x_1^{(1)} - x_1^{(0)}| = |3,6250 - 0| = 3,6250$$

$$|x_2^{(1)} - x_2^{(0)}| = |-1,1353 - 0| = 1,1353$$

$$|x_3^{(1)} - x_2^{(0)}| = |8,7714 - 0| = 8,7714$$

Jacobiho metóda

- **Druhá iterácia:** dosadíme $x_1^{(1)} = 3,6250$, $x_2^{(1)} = -1,1353$ a $x_3^{(1)} = 8,7714$ a vypočítame

$$x_1^{(2)} = \frac{1}{4} [14,5 - (-0,8) \cdot (-1,1353) - (-0,5) \cdot 8,7714] = 4,4944$$

$$x_2^{(2)} = \frac{1}{17} [-19,3 - 0,3 \cdot 3,6250 - (-0,9) \cdot 8,7714] = -0,7349$$

$$x_3^{(2)} = \frac{1}{7} [61,4 - 0,85 \cdot 3,6250 - (-0,2) \cdot (-1,1353)] = 8,2988$$

a spočítame rozdiely medzi iteráciami

$$|x_1^{(2)} - x_1^{(1)}| = |4,4944 - 3,6250| = 0,8694$$

$$|x_2^{(2)} - x_2^{(1)}| = |-0,7349 + 1,1353| = 0,4004$$

$$|x_3^{(2)} - x_3^{(1)}| = |8,2988 - 8,7714| = 0,4726$$

Jacobiho metóda

- **Tretia iterácia:** dosadíme $x_1^{(2)} = 4,4944$, $x_2^{(2)} = -0,7349$ a $x_3^{(2)} = 8,2988$ a vypočítame

$$x_1^{(3)} = \frac{1}{4} [14,5 - (-0,8) \cdot (-0,7349) - (-0,5) \cdot 8,2988] = 4,5154$$

$$x_2^{(3)} = \frac{1}{17} [-19,3 - 0,3 \cdot 4,4944 - (-0,9) \cdot 8,2988] = -0,7753$$

$$x_3^{(3)} = \frac{1}{7} [61,4 - 0,85 \cdot 4,4944 - (-0,2) \cdot (-0,7349)] = 8,2047$$

a opäť vyčíslime rozdiely medzi iteráciami

$$|x_1^{(3)} - x_1^{(2)}| = |4,5154 - 4,4944| = 0,0210$$

$$|x_2^{(3)} - x_2^{(2)}| = |-0,7753 + 0,7349| = 0,0404$$

$$|x_3^{(3)} - x_3^{(2)}| = |8,2047 - 8,2988| = 0,0941$$

Jacobiho metóda

- *Pseudo algoritmus Jacobiho metódy:*

```
Zvoľte počiatkový odhad  $x^{(0)}$  riešenia  $x$ .  
for  $k = 1, 2, \dots$   
  for  $i = 1, 2, \dots, n$   
     $\bar{x}_i = 0$   
    for  $j = 1, 2, \dots, i - 1, i + 1, \dots, n$   
       $\bar{x}_i = \bar{x}_i + a_{i,j}x_j^{(k-1)}$   
    end  
     $\bar{x}_i = (b_i - \bar{x}_i)/a_{i,i}$   
  end  
   $x^{(k)} = \bar{x}$   
  skontrolujte konvergenciu; pokračujte ak treba  
end
```



Gauss-Seidelova metóda

- Princíp *Gauss-Seidelovej metódy*² vysvetlíme na rovnakom príklade ako pri *Jacobiho metóde*, t. j.

$$\begin{aligned}x_1 &= 0 \cdot x_1 - \frac{a_{12}}{a_{11}}x_2 - \frac{a_{13}}{a_{11}}x_3 + \frac{b_1}{a_{11}}, \\x_2 &= -\frac{a_{21}}{a_{22}}x_1 + 0 \cdot x_2 - \frac{a_{23}}{a_{22}}x_3 + \frac{b_2}{a_{22}}, \\x_3 &= -\frac{a_{31}}{a_{33}}x_1 - \frac{a_{32}}{a_{33}}x_2 + 0 \cdot x_3 + \frac{b_3}{a_{33}}.\end{aligned}$$

²Autormi *Gauss-Seidelovej metódy* sú nemeckí matematici *Carl Friedrich Gauss* a *Philipp Ludwig von Seidel* (1821 - 1896).

Gauss-Seidelova metóda

- Gauss-Seidelova metóda je podobná Jacobiho metóde, s tým rozdielom, že *na výpočet iterácií jednotlivých súradníc vektora riešení používa predchádzajúce súradnice ihneď po ich vypočítaní*, t. j. *iteračný predpis* bude mať tvar

$$x_1^{(k)} = 0 \cdot x_1^{(k-1)} - \frac{a_{12}}{a_{11}}x_2^{(k-1)} - \frac{a_{13}}{a_{11}}x_3^{(k-1)} + \frac{b_1}{a_{11}},$$

$$x_2^{(k)} = -\frac{a_{21}}{a_{22}}x_1^{(k)} + 0 \cdot x_2^{(k-1)} - \frac{a_{23}}{a_{22}}x_3^{(k-1)} + \frac{b_2}{a_{22}},$$

$$x_3^{(k)} = -\frac{a_{31}}{a_{33}}x_1^{(k)} - \frac{a_{32}}{a_{33}}x_2^{(k)} + 0 \cdot x_3^{(k-1)} + \frac{b_3}{a_{33}}.$$



Gauss-Seidelova metóda

- Všeobecne pre výpočet hodnoty x_i pomocou *Gauss-Seidelovej metódy* môžeme napísať

$$x_i^{(k)} = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right). \quad (4)$$

- V tejto metóde využijeme fakt, že pri i -tej rovnici riešenia $(k+1)$ -vej iterácie poznáme okrem celého vektora $\mathbf{x}^{(k)}$ aj prvých $i-1$ zložiek vektora $(k+1)$ -vej iterácie. A teda tieto hodnoty môžeme využiť.

Gauss-Seidelova metóda

- Gauss-Seidelova metóda je ako Jacobiho metóda, až na to, že používa aktualizované hodnoty ako hneď ako budú k dispozícii.
- Vo všeobecnosti, ak Jacobiho metóda konverguje, Gauss-Seidel metóda bude konvergovať rýchlejšie ako Jacobiho metóda, aj keď stále relatívne pomaly.
- V inom maticovom vyjadrení môže byť Gauss-Seidelova metóda napísaná ako:

$$x^{(k)} = (D - L)^{-1}(Ux^{(k-1)} + b). \quad (5)$$

kde $U(D - L)^{-1} = \mathbf{B}$ a $(D - L)^{-1}b = \mathbf{c}$



Gauss-Seidelova metóda

- *Pseudo algoritmus Gauss-Seidelovej metódy:*

Zvoľte počiatočný odhad $x^{(0)}$ riešenia x .

for $k = 1, 2, \dots$

for $i = 1, 2, \dots, n$

$\sigma = 0$

for $j = 1, 2, \dots, i - 1$

$\sigma = \sigma + a_{i,j}x_j^{(k)}$

end

for $j = i + 1, \dots, n$

$\sigma = \sigma + a_{i,j}x_j^{(k-1)}$

end

$x_i^{(k)} = (b_{i,i} - \sigma) / a_{i,i}$

end

skontrolujte konvergenciu; pokračujte ak treba

end



SOR metóda

- *Metóda SOR* (Successive Over-Relaxation)³ je podobná Gauss-Seidelovej metóde, ale využíva relaxačný koeficient ω pre rýchlejšie dosiahnutie požadovanej presnosti riešenia.
- Metóda SOR je navrhnutá aplikáciou 'relaxácie' na Gauss-Seidelovu metódu. Táto 'relaxácia' má formu váženého priemeru medzi predchádzajúcou iteráciou a vypočítanou Gauss-Seidelovou iteráciou postupne pre každú zložku:

$$x_i^{(k)} = \omega \tilde{x}_i^{(k)} + (1 - \omega)x_i^{(k-1)}. \quad (6)$$

kde \tilde{x} označuje Gauss-Seidelovu iteráciu a ω je relaxačný faktor.

- Úlohou je vybrať ω ktoré urýchli rýchlosť konverencie k riešeniu.

³Autormi *SOR* metódy americkí matematici David Monaghan Young, Jr. (1923 - 2008) a Stan Frankel (1919 - 1978)

SOR metóda

- Všeobecný iteračný predpis pre výpočet hodnoty x_i pomocou *SOR metódy* je nasledovný

$$x_i^{(k)} = (1 - \omega)x_i^{(k-1)} + \frac{\omega}{a_{i,i}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right). \quad (7)$$

- Hodnota ω sa volí v intervale $(0, 2)$. Pre $\omega = 1$ je metóda totožná s Gauss-Seidelovu metódou.
- V inom maticovom vyjadrení môže byť SOR metóda napísaná ako:

$$x^{(k)} = (D - \omega L)^{-1}(\omega U + (1 - \omega)D)x^{(k-1)} + \omega(D - \omega L)^{-1}b. \quad (8)$$

SOR metóda

- Doteraz nie je známa metóda pre výber optimálnej hodnoty ω pre ľubovoľnú maticu A . Ale takéto kritérium je známe pre dôležitú triedu matíc.
- V práci Kahan⁴ je ukazané, že SOR nekonverguje, ak je ω mimo intervalu $(0, 2)$.
- Nech matica A je SPD a nech $0 < \omega < 2$. Potom metóda SOR konverguje pre ľubovoľný počiatočný vektor $x^{(0)}$.
- Jeden zo spôsobov výpočtu parametru

$$\omega_{opt} = \frac{2}{1 + \sqrt{1 - \rho^2}} \quad (9)$$

kde ρ je spektrálny polomer Jacobiho iteračnej matice.

⁴W. KAHAN, Gauss-Seidel methods of solving large systems of linear equations, PhD thesis, University of Toronto, 1958

SOR metóda

- *Pseudo algoritmus SOR metódy:*

Zvoľte počiatočný odhad $x^{(0)}$ riešenia x a hodnotu ω .

for $k = 1, 2, \dots$

for $i = 1, 2, \dots, n$

$\sigma = 0$

for $j = 1, 2, \dots, i - 1$

$\sigma = \sigma + a_{i,j}x_j^{(k)}$

end

for $j = i + 1, \dots, n$

$\sigma = \sigma + a_{i,j}x_j^{(k-1)}$

end

$\sigma = (b_{i,i} - \sigma)/a_{i,i}$

$x_i^{(k)} = (1 - \omega)x_i^{(k-1)} + \omega\sigma$

end

skontrolujte konvergenciu; pokračujte ak treba

end



Konvergenca

- Ak všeobecný iteračný proces (VIP): $x^{(k)} = \mathbf{B}x^{(k-1)} + \mathbf{c}$ konverguje, potom v limite $k \rightarrow \infty$ platí: $x^{(*)} = \mathbf{B}x^{(*)} + \mathbf{c}$.
- Nech $\rho(\mathbf{B})$ je spektrálny polomer matice \mathbf{B} a nech $\rho(\mathbf{B}) < 1$. Potom $(I - \mathbf{B})$ je regulárna a VIP konverguje pre ľubovoľný počiatočný vektor $x^{(0)}$. A naopak: ak VIP konverguje pre ľubovoľné $x^{(0)}$, potom $\rho(\mathbf{B}) < 1$.
- Ak je matica A SDD, potom Jacobiho i Gaussova-Seidelova metóda konvergujú pre ľubovoľný počiatočný vektor $x^{(0)}$, pričom Gaussova-Seidelova metóda konverguje rýchlejšie.
- Ak je matica A je SPD, potom Gaussova-Seidelova metóda konverguje pre ľubovoľný počiatočný vektor $x^{(0)}$.

Rýchlosť konverencie

- Nech A je konzistentne usporiadaná matica s nenulovými diagonálnymi prvkami. Nech sú všetky vlastné čísla matice \mathbf{B}_J Jacobiho iteračnej metódy reálne a nech $\rho(\mathbf{B}_J) < 1$. Nech R_{GS} a R_{SOR} značia rýchlosti konverencie metódy GS a SOR s optimálnou hodnotou relaxačného parametra ω . Potom

$$2\rho(\mathbf{B}_J)R_{GS}^{1/2} \leq R_{SOR} \leq R_{GS} + 2R_{GS}^{1/2} \quad (10)$$

pričom nerovnosť pravo platí, ak $R_{GS} \leq 3$.

