

NUMERICKÉ METÓDY LINEÁRNEJ ALGEBRY

06. Gradientné metódy.

Ing. Marek Macák, PhD.

Konzultácie: podľa potreby/dohody

11. Marec 2024

Úvod - Gradientné metódy

- Budeme venovať iteračným metódam založeným na minimalizácii kvadratickej funkcie, ktorej jediným minimom je práve riešenie systému $Ax = b$.
- Pre ľubovoľnú maticu A uvažujme napríklad kvadratickú funkciu

$$J(x) = r^T r = (b - Ax)^T (b - Ax) \quad (1)$$

ktorá je pozitívne definitná a svoje jediné minimum nadobúda, keď x je riešením systému $Ax = b$.

- V rámci jednoduchosti sa však zameriame len na symetrické a pozitívne definitné matice A .

Úvod - Gradientné metódy


- Pre symetrickú a pozitívne definitnú maticu A je riešenie systému $Ax = b$ ekvivalentné minimalizácii kvadratickej funkcie

$$H(x) = \frac{1}{2}x^T Ax - x^T b \quad (2)$$

- Táto kvadratická funkcia potom nadobúda svoje jediné minimum, keď x je riešením systému $Ax = b$.



Úvod - Gradientné metódy



Minimalizácia kvadratickej funkcie H .

Úvod - Gradientné metódy

- Hlavná myšlienka gradientných metód spočíva v zvolení počiatočnej aproximácie $x^{(0)}$ a následnom určení $x^{(1)}$ pomocou vzdialenosti $\alpha_{(0)}$ v zvolenom smere $v^{(0)}$ od bodu $x^{(0)}$.
- Všeobecný zápis týchto metód je teda tvaru

$$x^{(k)} = x^{(k-1)} + \alpha_{(k-1)} v^{(k-1)}, \quad k = 1, 2, \dots \quad (3)$$

- Jednotlivé metódy potom dostaneme konkrétnou voľbou smerových vektorov $v^{(k-1)}$.

Metóda najväčšieho spádu

- Smerové vektory $v^{(k-1)}$ zvolíme v smere najväčšieho spádu, t.j. najväčšej zmeny kvadratickej funkcie H .
- Vzdialenosť $\alpha^{(k-1)}$ určíme tak, aby funkcia H nadobúdala v bode

$$x^{(k)} = x^{(k-1)} + \alpha^{(k-1)} v^{(k-1)}, \quad (4)$$

svoje minimum v smere $v^{(k-1)}$.



Metóda najväčšieho spádu

Geometricky môžeme metódu interpretovať nasledovne:

- Nech $x^{(0)}$ je počiatočná aproximácia riešenia sústavy $Ax = b$.
- Priamka prechádzajúca bodmi $x^{(0)}$ a $v^{(0)}$ je všeobecne tvaru $x = x^{(0)} + \alpha v^{(0)}$, $\alpha \in \mathbb{R}$
- Body ležiace na tejto priamke predstavujú krivku

$$H\left(x^{(0)} + \alpha v^{(0)}\right) = \frac{1}{2}x^{(0)T}Ax^{(0)} + \alpha v^{(0)T}\left(Ax^{(0)} - b\right) + \frac{1}{2}\alpha^2 v^{(0)T}Av^{(0)} - x^{(0)T}b, \quad (5)$$

na ploche zodpovedajúcej kvadratickej funkcii in $H \in \mathbb{R}^n$.

Metóda najväčšieho spádu

- Hladáme smerový vektor $v^{(0)}$ ktorom má plocha H najväčší spád. Hladáme maximum prvej derivácie funkcie H pre $\alpha = 0$

$$\left. \frac{\partial H(x^{(0)} + \alpha v^{(0)})}{\partial \alpha} \right|_{\alpha=0} = v^{(0)T} (Ax^{(0)} - b) \quad (6)$$

Skalárny súčin z výrazu je maximálny pre $v^{(0)} = Ax^{(0)} - b = -r^{(0)}$. Teda smer najväčšieho spádu plochy H je opačný vzhľadom k smeru reziduového vektora $r^{(0)}$.

- Ďalej hladáme na priamke x bod $x^{(1)}$ v ktorom nadobúda plocha H svoje minimum

$$\frac{\partial H(x^{(0)} + \alpha r^{(0)})}{\partial \alpha} = r^{(0)T} r^{(0)} + \alpha r^{(0)T} A r^{(0)} = 0 \quad \rightarrow \quad \alpha = -\frac{r^{(0)T} r^{(0)}}{r^{(0)T} A r^{(0)}} \quad (7)$$

Metóda najväčšieho spádu

- Jednoznačnosť minima overíme pomocou druhej derivácie

$$\frac{\partial^2 H(x^{(0)} + \alpha r^{(0)})}{\partial \alpha^2} = r^{(0)T} A r^{(0)} \quad (8)$$

Pre pozitívne definitnú maticu A a $r^{(0)} \neq \mathbf{0}$ je $r^{(0)T} A r^{(0)} > 0$. Funkcia H je teda konvexná vzhľadom k premennej α a minimum, ktoré nadobúda v bode

$$x^{(1)} = x^{(0)} + \frac{r^{(0)T} r^{(0)}}{r^{(0)T} A r^{(0)}} r^{(0)} \quad (9)$$

je jediné.



Metóda najväčšieho spádu

- Všeobecný zápis metódy najväčšieho spádu je potom tvaru

$$x^{(k)} = x^{(k-1)} + \alpha_{k-1} r^{(k-1)} \quad (10)$$

kde

$$\alpha_{k-1} = - \frac{r^{(k-1)T} r^{(k-1)}}{r^{(k-1)T} A r^{(k-1)}}. \quad (11)$$



Metóda združených gradientov

- Je založená na konštrukcii smerových vektorov $v^{(i)}$ tak, aby boli A -ortogonálne.
- Nech $A \in \mathbb{M}_n$ je symetrická a pozitívne definitná matica. Nenulové vektory $v^{(i)}$ a $v^{(j)}$ nazývame združené vzhľadom k A alebo A -ortogonálne, ak platí

$$v^{(j)T} A v^{(i)} = 0, \quad i \neq j \quad (12)$$

- Nenulové vektory $v^{(0)}, v^{(1)}, \dots, v^{(m-1)}$ sú A -ortogonálne, a tiež platí, že sú navzájom lineárne nezávislé.

Metóda združených gradientov

- Takto definované A-ortogonálne vektory $v^{(0)}, v^{(1)}, \dots, v^{(m-1)}$ tvoria bázu n-rozmerného euklidovského priestoru a presné riešenie x^* systému $Ax = b$ môžeme vyjadriť ako ich lineárnu kombináciu

$$x^* = \alpha_0 v^{(0)} + \alpha_1 v^{(1)} + \dots + \alpha_{n-1} v^{(n-1)} \quad (13)$$

kde

$$\alpha_i = \frac{v^{(i)T} A x^*}{v^{(i)T} A v^{(i)}} = \frac{v^{(i)T} b}{v^{(i)T} A v^{(i)}}. \quad (14)$$

- Je dôležité poznamenať, že koeficienty α_i teda vieme vypočítať aj bez znalosti presného riešenia x^* .

Metóda združených gradientov

- Nech $v^{(0)}, v^{(1)}, \dots, v^{(m-1)}$ sú nenulové A -ortogonálne vektory v \mathbb{R}^n . Potom pre ľubovoľnú počiatočnú aproximáciu $x^{(0)} \in \mathbb{R}^n$ má postupnosť $x^{(k)}$ daná vzťahom

$$x^{(k)} = x^{(k-1)} + \alpha_{k-1} v^{(k-1)}, \quad \text{kde} \quad \alpha_{k-1} = \frac{v^{(k-1)T} r^{(k-1)}}{v^{(k-1)T} A v^{(k-1)}} \quad \text{a} \quad k \geq 1 \quad (15)$$

nasledujúce vlastnosti:

- Postupnosť konverguje k presnému riešeniu x^* systému $Ax = b$ v nanajvýš n krokoch.
- Kvadratická funkcia $H(x)$ dosahuje svoje minimum v bode x^* .

Metóda združených gradientov

- Ako teda zostrojiť vhodnú postupnosť A-ortogonálnych vektorov?
- Nech $u^{(0)}, u^{(1)}, \dots, u^{(m-1)}$ tvoria bázu v \mathbb{R}^n . Potom postupnosť $\{v^i\}$

$$v^{(0)} = u^{(0)}, \quad (16)$$

$$v^{(i)} = u^{(i)} + \sum_{j=0}^{i-1} \beta_{i,j} v^{(j)}, \quad i = 1, 2, \dots, n-1. \quad (17)$$

kde koeficienty $\beta_{i,j}$ sú tvaru

$$\beta_{i,j} = -\frac{v^{(j)T} A u^{(i)}}{v^{(j)T} A v^{(j)}} \quad (18)$$

Metóda združených gradientov

- Ak zvolíme za postupnosť $\{u^i\}$ postupnosť reziduových vektorov $\{r^i\}$ dostaneme metódu A–združených gradientov. Počiatočnú aproximáciu $x^{(0)} \in \mathbb{R}^n$ máme v tvare

$$v^{(0)} = u^{(0)} = r^{(0)} = b - Ax^{(0)} \quad (19)$$

a pre $i = 1, 2, \dots$ platia nasledujúce vzťahy

$$\alpha_{i-1} = \frac{v^{(i-1)T} r^{(i-1)}}{v^{(i-1)T} A v^{(i-1)}}, \quad (20)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1} v^{(i-1)}, \quad (21)$$

$$r^{(i)} = b - Ax^{(i)} = r^{(i-1)} - \alpha_{i-1} A v^{(i-1)}, \quad (22)$$

$$\beta_{i-1} = -\frac{v^{(i-1)T} A r^{(i)}}{v^{(i-1)T} A v^{(i-1)}}, \quad (23)$$

$$v^{(i)} = r^{(i)} + \beta_{i-1} v^{(i-1)}, \quad (24)$$

Zastavovacie kritéria

- Iteračne metódy vytvára postupnosť $\{x^{(i)}\}$ vektorov konvergujúcich k vektoru x^* spĺňajúcemu $Ax^* = b$.
- Aby bol výpočet efektívny, musí sa rozhodnúť, kedy sa má zastaviť.
- Dobré zastavenie kritérium by malo:
 - určiť, kedy je chyba $e^{(i)} = x^{(i)} - x^*$ dostatočne malá na zastavenie,
 - zastaviť výpočet, ak chyba už neklesá alebo klesá príliš pomaly, a
 - obmedziť maximálny čas strávený výpočtom.



Zastavovacie kritéria

- Používateľ môže zadávať veličiny *maxit*, $\|b\|$, *stop_tol* a najlepšie aj $\|A\|$:
 - Celé číslo *maxit* je maximálny počet iterácií, ktoré bude môcť algoritmus vykonať.
 - Reálne číslo $\|A\|$ je norma A . Každá rozumná (rádovo) aproximácia absolútnej hodnoty najväčšej položky matice A .
 - Reálne číslo $\|b\|$ je norma b . Opäť platí, že akákoľvek rozumná aproximácia absolútnej hodnoty najväčšej hodnoty vektora b .
 - Reálne číslo *stop_tol* meria, ako malý bude zostatok $r^{(i)} = Ax^{(i)} - b$ konečného riešenia $x^{(i)}$. Jedným zo spôsobov, ako zvoliť *stop_tol*, je približná aproximácia hodnôt v A a b vzhľadom na $\|A\|$, resp. $\|b\|$. Napríklad, voľba *stop_tol* = 10^{-6} znamená, že používateľ berie do úvahy hodnoty v A a b s chybou v rozsahu $\pm 10^{-6}\|A\|$ a $\pm 10^{-6}\|b\|$. *stop_tol* by malo byť väčšie ako strojová presnosť ϵ .

Zastavovacie kritéria

- Algoritmus výpočtu vieme zapísať nasledovne:

$i = 1$

Do $i = i + 1$

Spočítaj aproximáciu riešenia $x^{(i)}$.

Spočítaj rezíduum $r^{(i)} = Ax^{(i)} - b$.

Spočítaj $\|r^{(i)}\|$ a $\|x^{(i)}\|$.

until $i \geq \text{maxit}$ or $\|r^{(i)}\| \leq \text{stop_tol} \cdot (\|A\| \cdot \|x^{(i)}\| - \|b\|)$.

- Ak $\|A\|$ nie je k dispozícii, môže byť zastavovacie kritérium nahradené

until $i \geq \text{maxit}$ or $\|r^{(i)}\| \leq \text{stop_tol} \cdot \|b\|$.

- Ak poznáme $\|A^{-1}\|$

until $i \geq \text{maxit}$ or $\|r^{(i)}\| \leq \text{stop_tol} \cdot \|x^{(i)}\| / \|A^{-1}\|$.

Zastavovacie kritéria

- Existujú dva prístupy k obmedzeniu nepresnosti vypočítaného riešenia $Ax = b$.
- Keďže $e^{(i)} = x^{(i)} - x^*$, ktorú budeme nazývať dopredná chyba, je ťažké odhadnúť priamo, zavedieme spätnú chybu, ktorá nám umožňuje ohraničiť doprednú chybu.
- Normovaná spätná chyba je definovaná ako najmenšia možná hodnota $\max\{\|\delta A\|/\|A\|, \|\delta b\|/\|b\|\}$, kde $x^{(i)}$ je presné riešenie $(A + \delta A)x^{(i)} = (b + \delta b)$.
- Spätná chyba sa dá ľahko vypočítať z rezidua $r^{(i)} = Ax^{(i)} - b$.
- Za predpokladu, že máme nejaké ohranícenie pre inverznú hodnotu A , môžeme ohraničiť doprednú chybu v termínoch spätnej chyby prostredníctvom jednoduchšej rovnice

$$e^{(i)} = x^{(i)} - x^* = A^{-1}(Ax^{(i)} - b) = A^{-1}r^{(i)}, \quad (25)$$

co vedie na $\|e^{(i)}\| \leq \|A^{-1}\| \cdot \|r^{(i)}\|$.

Zastavovacie kritéria

- Kriterium:

$$\text{until } i \geq \text{maxit} \text{ or } \|r^{(i)}\| \leq \text{stop_tol} \cdot (\|A\| \cdot \|x^{(i)}\| - \|b\|).$$

- Sa rovná požiadavke, aby chyby $\|\delta A\|$ a $\|\delta b\|$ spĺňali $\|\delta A\| \leq \text{stop_tol} \cdot \|A\|$ a $\|\delta b\| \leq \text{stop_tol} \cdot \|b\|$.
- Toto kritérium dáva ohraničenie doprednej chyby

$$\|e^{(i)}\| \leq \|A^{-1}\| \cdot \|r^{(i)}\| \leq \text{stop_tol} \cdot \|A^{-1}\| \cdot (\|A\| \cdot \|x^{(i)}\| - \|b\|). \quad (26)$$

Zastavovacie kritéria

- Kriterium:

$$\text{until } i \geq \text{maxit} \text{ or } \|r^{(i)}\| \leq \text{stop_tol} \cdot \|b\|.$$

- Sa rovná požiadavke, aby chyby $\|\delta A\|$ a $\|\delta b\|$ spĺňali $\delta A = 0$ a $\|\delta b\| \leq \text{stop_tol} \cdot \|b\|$.
- Jedným z problémov je, že ak $\|A\| \cdot \|x\| \geq \|b\|$, čo môže nastať len vtedy, ak je A veľmi zle podmienená a x leží v nulovom priestore A . Potom môže byť pre akúkoľvek metódu ťažké splniť toto kritérium zastavenia.
- Na To, že A je zle podmienená vedie na

$$1 \ll \frac{\|A\| \cdot \|x\|}{\|b\|} = \frac{\|A\| \cdot \|A^{-1}b\|}{\|b\|} \leq \|A\| \cdot \|A^{-1}\| \quad (27)$$

- Toto kritérium dáva ohraničenie doprednej chyby

$$\|e^{(i)}\| \leq \|A^{-1}\| \cdot \|r^{(i)}\| \leq \text{stop_tol} \cdot \|A^{-1}\| \cdot \|b\|. \quad (28)$$

Zastavovacie kritéria

- Kriterium:

$$\text{until } i \geq \text{maxit} \text{ or } \|r^{(i)}\| \leq \text{stop_tol} \cdot \|x^{(i)}\| / \|A^{-1}\|.$$

- Toto kritérium vedie na ohraničenie doprednej chyby

$$\frac{\|e^{(i)}\|}{\|x^{(i)}\|} \leq \frac{\|A^{-1}\| \cdot \|r^{(i)}\|}{\|x^{(i)}\|} \leq \text{stop_tol}. \quad (29)$$

umožňuje používateľovi určiť požadovanú relatívnu hranicu presnosti *stop_tol* vo vypočítanom riešení $x^{(i)}$.