

# NUMERICKÉ METÓDY LINEÁRNEJ ALGEBRY

- 09. Základné algoritmy pre výpočet vlastných čísiel a vektorov,
- 10. Spôsoby prepodmienenia pri riešení sústav lineárnych rovníc.

Ing. Marek Macák, PhD.

Konzultácie: podľa potreby/dohody

22. Apríl 2024

## Opakovanie?

---

- Nech  $A \in \mathbb{C}^{n \times n}$ . Potom  $\lambda$  je vlastné číslo matice  $A$ , ak existuje nenulový vektor  $x$  taký, že platí

$$Ax = \lambda x \leftrightarrow (A - \lambda I)x = 0. \quad (1)$$

- Množina vlastných čísiel sa nazýva **spektrum** matice  $A$ .
- Vektor  $x \neq 0$  sa nazýva (pravý) vlastný vektor matice  $A$  prislúchajúci k vlastnému číslu  $\lambda$ .
- Vektor  $y \neq 0$ , ktorý vyhovuje rovnici  $y^T A = \lambda y^T$  sa nazýva ľavý vlastný vektor matice  $A$  prislúchajúci k vlastnému číslu  $\lambda$ .
- Homogénny systém rovníc  $(A - \lambda I)x = 0$  má nenulové riešenie práve vtedy, ak  $\det(A - \lambda I) = 0$ .

## Opakovanie?

---

- Polynóm premennej  $\lambda$  definovaný ako

$$P_\lambda = \det(A - \lambda I) \quad (2)$$

má stupeň  $n$  a nazýva sa charakteristický polynóm matice  $A$ . Takže vlastné čísla matice  $A$  sú korene jej charakteristického polynómu.

- Regulárna matica  $A$  má nenulové vlastné čísla. Ak  $(\lambda, x)$  je vlastný pár regulárnej matice  $A$ , potom  $(1/\lambda, x)$  je korešpondujúci vlastný pár matice  $A^{-1}$ .  $(\lambda - \sigma, x)$  je vlastný pár matice  $A - \sigma I$  a  $(\lambda^k, x)$  je vlastný pár matice  $A^k$ .
- Vlastné čísla trojuholníkovej matice sú jej diagonálne prvky.
- Nech  $T$  je regulárna matica. Potom matice  $A$  a  $TAT^{-1}$  majú rovnaké vlastné čísla (matica  $TAT^{-1}$  je podobná matici  $A$ ).

## Opakovanie??

---


- Z Abel-Ruffiniho vety plyne, že nie je možné zostrojiť priamu metódu pre výpočet kompletného spektra matice pro  $n \geq 5$ .
- Všetky metódy výpočtu spektier matíc sú preto iteračné.
- Potrebné je poznať nejaký odhad chyby, aby bolo možné určiť vhodné kritérium zastavenia pri výpočte iterácií.
- Nech  $A \in \mathbb{C}^{n \times n}$  je hermitovská matica a nech  $\tilde{\lambda}$  a  $\tilde{x} \neq 0$  sú pripísané aproximácie vlastnej hodnoty a vlastného čísla  $\lambda$  vektora  $x$ . Pre rezíduum

$$r = A\tilde{x} - \tilde{\lambda}\tilde{x} \quad (3)$$

potom

$$\min_{\lambda_i \in \rho(A)} |\tilde{\lambda} - \lambda_i| \leq \frac{\|r\|}{\|\tilde{x}\|} \quad (4)$$

# Úvod



*Modelovanie a analýza vibrácií.*

# Úvod

---



*Modelovanie a analýza vibrácii - Tacoma bridge.*

Tacoma bridge



## Lokalizacia

- V niektorých aplikáciách (napr. stabilita dynamických systémov, konvergencia iteračných metód a pod.) nie sú dôležité hodnoty vlastných čísiel, ale ich lokalizácia v komplexnej rovine ( $\operatorname{Re}(\lambda) < 0, |\lambda| < 1$ ).
- Geršgorin (1931): Nech  $A \in \mathbb{R}^{n \times n}$ . Položme

$$r_i = \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n. \quad (5)$$

Potom každé vlastné číslo  $\lambda$  splna aspoň jednu z nasledujúcich nerovností:

$$|\lambda - a_{ii}| \leq r_i, \quad i = 1, 2, \dots, n. \quad (6)$$

t.j. spektrum matice  $A$  leží v zjednotení  $n$  Geršgorinových diskov  
 $z \in \mathbb{C} : |\lambda - a_{ii}| \leq r_i, i = 1, 2, \dots, n$ .

## Lokalizacia

---

- Nech  $r$  Geršgorinových diskov je disjunktných vzhľadom na zostávajúcich  $n - r$  diskov ( $r < n$ ). Potom zjednotenie týchto  $r$  diskov obsahuje presne  $r$  vlastných čísiel matice  $A$ .
- Príklad:

$$A = \begin{pmatrix} 1 & 0.2 & 0.1 \\ 0.2 & 4 & 0.3 \\ 0.4 & 0.5 & 8 \end{pmatrix} \quad (7)$$

- Riesenie ....
- Všetky 3 disky sú navzájom disjunktné, takže každý z nich obsahuje práve jedno vlastné číslo ( $\lambda_1 = 0.9834$ ,  $\lambda_2 = 3.9671$ ,  $\lambda_3 = 8.0495$ ).



Ako na to?



## Mocninová metóda (MM)

---

- Príklad:

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \quad (8)$$

.....

- Ak by  $A$  nebolo diagonálna ale všeobecná výpočet by  $A^k$  by bol náročný
- Výpočet  $k$ -tej mocniny môžeme nahradiť

$$x^{(k+1)} = Ax^{(k)} \quad (9)$$

čo možno prepísať

$$x^{(k)} = A^k x^{(0)} \quad (10)$$

## Mocninová metóda (MM)

---

- Videli sme že je dôležité aby hlavná zložka vektora bola nenulová, to znamená  $x^{(0)}$  musí mať nenulový priemet do smeru najväčšieho vlastného čísla.
- Delením  $3^k$  sme urobili tak, že výsledný postupnosť  $x^{(k)}$  konverguje. Inak by sme dostali postupnosť vektora, ktorá síce konvergujú do smeru najväčšieho vlastného vektora, ale by rástli do nekonečna.
- Vo všeobecnosti môžeme deliť najväčšou zložku výsledného vektora. Potom dostaneme tzv. mocninovu metódu



## Mocninová metóda (MM)

---

- Nech  $A$  má VC :  $|\lambda_1| > |\lambda_2| \leq |\lambda_3| \leq |\lambda_n|$  a nech  $v_1$  je VV prislúchajúci k  $\lambda_1$ . Nech je  $A$  diagonalizovateľná.
- Tato metóda konštruuje postupnosť

$$y^{(k+1)} = Ax^{(k)} \quad (11)$$

$$\alpha_k = \max(x^{(k+1)}) \quad (12)$$

$$x^{(k+1)} = y^{(k+1)} / \alpha_k \quad (13)$$

za vhodných predpokladov  $x^{(k)}$  konverguje k najväčšiemu vlastnému vektoru a  $\alpha_k$  k najväčšiemu číslu.

## Mocninová metoda (MM)

---

- Nech je  $A$  diagonalizovatelná

Zvol  $x^{(0)} \neq 0, tol, k = 0$   
**Do**  $k = k + 1$   
 $\tilde{x}^{(k)} = Ax^{(k-1)}.$   
 $\lambda_m = \max(\tilde{x}^{(k)}).$   
 $x^{(k)} = \frac{1}{\lambda_m} \tilde{x}^{(k)}.$   
 $r^{(k)} = Ax^{(k)} - \lambda_m x^{(k)}.$   
**until**  $k \geq maxit$  or  $\|r^{(k)}\| \geq |tol|.$



## Mocninová metoda (MM)

- Příklad 1:

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad x^{(0)} = (1, 1)^T \quad (14)$$

potom

k	$y^{(k+1)}$	$\alpha_k$	$x^{(k+1)}$
0	$(3, 2)^T$	3	$(1, \frac{2}{3})^T$
1	$(3, \frac{4}{3})^T$	3	$(1, \frac{4}{9})^T$
2	$(3, \frac{8}{9})^T$	3	$(1, \frac{8}{27})^T$
.	.	.	.
.	.	.	.
.	.	.	.
i	$(3, \frac{2^{i+1}}{3^i})^T$	3	$(1, (\frac{2}{3})^{i+1})^T$

## Mocninová metóda (MM)

- Príklad 2:

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad x^{(0)} = (0, 1)^T \quad (15)$$

potom

k	$y^{(k+1)}$	$\alpha_k$	$x^{(k+1)}$
0	$(0, 2)^T$	2	$(0, 1)^T$
1	$(0, 2)^T$	2	$(0, 1)^T$
2	$(0, 2)^T$	2	$(0, 1)^T$
⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮
i	$(0, 2)^T$	2	$(0, 1)^T$



## Mocninová metoda (MM)

- Příklad 3:

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad x^{(0)} = (\epsilon, 1)^T \quad (16)$$

potom

k	$y^{(k+1)}$	$\alpha_k$	$x^{(k+1)}$
0	$(3\epsilon, 2)^T$	2	$(\frac{3}{2}\epsilon, 1)^T$
1	$(\frac{9}{2}\epsilon, 2)^T$	2	$(\frac{9}{4}\epsilon, 1)^T$
.	.	.	.
i-1	$(\frac{3^i}{2^{i-1}}\epsilon, 2)^T$	2	$(\frac{3^i}{2^i}\epsilon, 1)^T$
i	$(\frac{3^{i+1}}{2^i}\epsilon, 2)^T$	$\frac{3^{i+1}}{2^i}\epsilon$	$(1, \frac{2^i}{3^{i+1}}\epsilon)^T$
i+1	$(3, \frac{2^{i+1}}{3^{i+1}}\epsilon)^T$	3	$(1, \frac{2^{i+1}}{3^{i+2}}\epsilon)^T$
.	.	.	.



## Mocninová metóda (MM)

---

- Ak chceme nájsť najmenšie vlastné číslo v absolútnej hodnote matice  $A$ , môžeme použiť mocninovú metódu na maticu  $A^{-1}$ .
- Najmenšia hodnota vlastného čísla potom bude  $1/\lambda$ .
- Krok  $y^{(k+1)} = A^{-1}x^{(k)}$  potom riešime ako  $Ay^{(k+1)} = x^{(k)}$   
Týmto trikom sa zbavíte výpočtu inverzie matice a používa v numerike používa veľmi často.



## Mocninová metóda (MM)

---

- Pokiaľ budeme  $x^{(0)}$  voliť náhodne, potom je nulová pravdepodobnosť trafiť vektor s nulovým priemetom do najväčšieho vlastného vektora.
- V praxi je u reálnych ulož zaistene že zaokrúhľovacie chyby vnesú do výpočtu potrebné  $\epsilon$ .
- Rýchlosť konvergenzie metódy je daná podielom  $|\lambda_2|/|\lambda_1|$



## Princíp deflácie (Redukčná metóda)

- Deflácia je metóda na výpočet subdominantného vlastného čísla (VC) a vlastného vektora (VV):  $|\lambda_1| > |\lambda_2| > |\lambda_3| \geq \dots \geq |\lambda_n|$ . Pritom sa predpokladá, že k dispozícii je kvalitný odhad dominantného páru  $(\lambda_1, x_1)$ .
- Householderova matica  $H$  (elementárna reflexia): Nech  $e_1 = (1, 0, \dots, 0)^T$  a nech  $x = (x_1, x_2, \dots, x_n)^T \neq \alpha e_1$ , potom existuje vektor  $u$

$$u = x + \operatorname{sgn}(x_1) \|x\|_2 e_1 \quad (17)$$

Taký že

$$H = I - 2 \frac{uu^T}{u^T u}, \quad Hx = -\operatorname{sgn}(x_1) \|x\|_2 e_1. \quad (18)$$

je symetrická, ortogonálna.

## Princíp deflácie (Redukčná metóda)

---

- Nech  $(\lambda_1, x_1)$  je dominantný vlastný pár matice  $A$  a nech  $H$  je také HM, že  $Hv_1 = \lambda e_1$ . Potom

$$A_1 = H^{-1}AH = \begin{pmatrix} \lambda_1 & c^T \\ 0 & A_2 \end{pmatrix} \quad (19)$$

kde  $A_2$  je rádu  $n - 1$  a má tie isté vlastné čísla ako  $A$  okrem  $\lambda_1$ . Matica  $H$  je maticou prechodu medzi bazami.

- Dokaz ...
- Ak teda  $|\lambda_1| > |\lambda_2| > |\lambda_3| \geq \dots \geq |\lambda_n|$ , potom po deflačnom kroku  $A_1 = HAH$  je  $\lambda_2$  dominantné VC matice  $A_2$ .

## Princíp deflácie (Redukčná metóda)

- Tvar  $H$  je taký že stĺpce tvoria bázičné vektory

$$H = \begin{pmatrix} x_1 & & & 0 \\ x_2 & 1 & & \\ \vdots & & \ddots & \\ x_n & 0 & & 1 \end{pmatrix} \quad (20)$$

- Inverznú maticu dostaneme tak že prvý stĺpce podelíme  $x_1$

$$H^{-1} = \begin{pmatrix} \frac{1}{x_1} & & & 0 \\ -\frac{x_2}{x_1} & 1 & & \\ \vdots & & \ddots & \\ -\frac{x_n}{x_1} & 0 & & 1 \end{pmatrix} \quad (21)$$

## Princíp deflácie (Redukčná metóda)

- Roznásobením dostaneme maticu  $A_2$

$$A_2 = \begin{pmatrix} a_{22} - \frac{x_2}{x_1} a_{12} & a_{23} - \frac{x_2}{x_1} a_{13} & \cdots & a_{2n} - \frac{x_2}{x_1} a_{1n} \\ a_{32} - \frac{x_3}{x_1} a_{12} & a_{33} - \frac{x_3}{x_1} a_{13} & \cdots & a_{3n} - \frac{x_3}{x_1} a_{1n} \\ \vdots & & \ddots & \vdots \\ a_{n2} - \frac{x_n}{x_1} a_{12} & a_{n3} - \frac{x_n}{x_1} a_{13} & \cdots & a_{nn} - \frac{x_n}{x_1} a_{1n} \end{pmatrix} \quad (22)$$

- Podobne ide napísať

$$c^T = \frac{1}{x_1} (a_{12}, a_{13}, \dots, a_{1n}) \quad (23)$$

- Teraz vieme pre maticu  $A_2$  nájsť vlastné číslo  $\lambda_2$  a vlastný vektor napr.  $\vec{z} = (z_2, \dots, z_n)^T$ .

## Princíp deflácie (Redukčná metóda)

- Ako dopočítať odpovedajúci vlastný vektor matice  $A$ ?
- Logicky ako lineárna kombinácia báзовého vektora daného stĺpcami matice  $H$ . Na to však potrebujeme vypočítať zložku  $z_1$ .
- Musí byť platiť

$$\begin{pmatrix} \lambda_1 & c^T \\ 0 & A_2 \end{pmatrix} \begin{pmatrix} z_1 \\ \vec{z} \end{pmatrix} = \begin{pmatrix} \lambda_1 z_1 + c^T \vec{z} \\ A_2 \vec{z} \end{pmatrix} = \begin{pmatrix} \lambda_1 z_1 + c^T \vec{z} \\ \lambda_2 \vec{z} \end{pmatrix} = \begin{pmatrix} \lambda_2 z_1 \\ \lambda_2 \vec{z} \end{pmatrix} \quad (24)$$

odtiaľ dostávame

$$\lambda_1 z_1 + c^T = \lambda_2 z_1 \rightarrow z_1 = \frac{c^T \vec{z}}{\lambda_2 - \lambda_1} \quad (25)$$

- Teraz vieme pre maticu  $A_2$  nájsť vlastne číslo  $\lambda_2$  a vlastný vektor napr.  $\vec{z} = (z_2, \dots, z_n)^T$ .

## Princíp deflácie (Redukčná metóda)

---

- Výpočet počtu najväčších, resp. najmenších vlastných čísel. matice  $A$ , sa používa nasledujúca kombinácia MM, MII a deflace:
  - 1) Použi mocninou metódu aplikovanú na  $A$  (resp. mocninou metódu aplikovanú na  $A^{-1}$ ) na výpočet dobrej aproximácie v absolútnej hodnote najväčšieho (resp. najmenšieho) VC a príslušného VV.
  - 2) Aplikuj metódu inverzných iterácií s aproximovaným VC (zostáva nemenné) a s aproximovaným VV z kroku 1 ako počítačným vektorom. Takto sa získa spravidla veľmi spresnený odhad VV
  - 3) Aplikuj defláciu na výpočet ďalšieho vlastného páru
  - 4) Opakuj kroky 1-3 pre požadovaný počet vlastných párov





## Metóda inverzných iterácií (MII)

- Ak je k dispozícii kvalitná aproximácia  $\sigma$  dominantného VC  $\lambda_1$ , potom MII efektívne počíta prislúchajúci VV.
- Kvalitná aproximácia:  $|\lambda_1 - \sigma| \ll |\lambda_i - \sigma|, i = 2, \dots, n$ .
- Presnosť počítača: konštanta  $\epsilon$ ; pri dvojitej presnosti je  $\epsilon \approx 1.11 \times 10^{-16}$ .

Zvol  $x^{(0)} \neq 0, \sigma, k = 0$

**Do**  $k = k + 1$

Najdi  $x^{(k)}$  riešením  $(A - \sigma I)\tilde{x}^{(k)} = x^{(k-1)}$ .

$\lambda_m = \max(\tilde{x}^{(k)})$ .

$x^{(k)} = \frac{1}{\lambda_m} \tilde{x}^{(k)}$ .

$x^{(k)} = x^{(k)} / \|x^{(k)}\|$ .

$r^{(k)} = Ax^{(k)} - \sigma x^{(k)}$ .

**until**  $k \geq \text{maxit}$  or  $\|r^{(k)}\| \geq \|A\|\epsilon$ .

## Metóda inverzných iterácií (MII)

---

- MII je vlastne mocninová metóda aplikovaná na maticu  $(A - \sigma I)^{-1}$ , pričom je k dispozícii kvalitná aproximácia  $\sigma$  VC  $\lambda_1$ , ktorá sa počas iterácií nemení.
- Kombinácia MM a MII, kde MII slúži na spresnenie odhadu VV. Obvykle totiž MM dáva omnoho presnejší odhad VC než korešpondujúceho VV.
- Ak máme k dispozícii kvalitný odhad  $\sigma$  ľubovoľného VC  $\lambda_j$  potom MII spravidla veľmi rýchlo konverguje k VV prislúchajúcemu k  $\lambda_j$ .



# NUMERICKÉ METÓDY LINEÁRNEJ ALGEBRY

- 09. Základné algoritmy pre výpočet vlastných čísiel a vektorov,
- 10. Spôsoby prepodmienenia pri riešení sústav lineárnych rovníc.

Ing. Marek Macák, PhD.

Konzultácie: podľa potreby/dohody

22. Apríl 2024

## Prečo?


---

- Nedostatočná robustnosť je všeobecne uznávanou slabinou iteratívnych metod v porovnaní s priamym metódami.
- Tento nedostatok bráni prijatiu iteračných metód napriek ich vhodnosti pre veľmi veľké lineárne systémy.
- Obidve stránky účinnosť aj robustnosť iteračných techník možno zlepšiť použitím predpodmienenia.
- Predpodmienenie je jednoducho prostriedok na transformáciu pôvodného lineárneho systému na systém, ktorý má rovnaké riešenie, ale ktorý sa bude pravdepodobne ľahšie riešiť iteračnou metódou.
- Vo všeobecnosti je spoľahlivosť iteračných techník pri riešení rôznych aplikácií veľmi závislá viac na kvalite predpodmienenia ako na použitých konkrétnych akceleračtoroch Krylovovho podpriestoru.

# Ako?

---

- Prvým krokom pri predpodmienení je nájsť maticu predpodmienenia (preconditioning matrix)  $M$ .
- Matica  $M$  môže byť definovaná rôznymi spôsobmi, ale musí spĺňať niekoľko minimálnych požiadaviek:
  - Z praktického hľadiska je najväčšou požiadavkou na  $M$  to, aby bola nenáročná na riešenie lineárnych systémov  $Mx = b$ .
  - Taktiež  $M$  by mala byť v určitom zmysle blízka  $A$  a mala by byť jednoznačne nesusingulárna.
- Keď je k dispozícii matica predpodmienenia  $M$ , sú známe tri spôsoby použitia predpodmienenia.



## Ako?

---

- Predpodmienenie sa môže aplikovať zľava, čo vedie k predpodmienenému systému:

$$M^{-1}Ax = M^{-1}b. \quad (26)$$

- Prípadne sa môže použiť aj vpravo:

$$AM^{-1}u = b, \quad u = Mx, \quad x = M^{-1}u. \quad (27)$$

- Nakoniec, keď je predpodmienenie k dispozícii vo faktorovanej forme  $M = M_L M_U$  kde  $M_L$  a  $M_U$  sú trojuholníkové matice, predpodmienenie môžeme napísať ako:

$$M_L^{-1}AM_U^{-1}u = M_L^{-1}b, \quad x = M_U^{-1}u, \text{ alebo } u = M_U x. \quad (28)$$

Ako dostanem maticu  $M$ ?



## Jacobi Preconditioning

---

- Najjednoduchší predpodmienovač je zostavený len z diagonály matice:

$$m_{i,j} = \begin{cases} a_{i,j} & \text{if } i = j \\ 0 & \text{inak} \end{cases} \quad (29)$$

- Je možné použiť bez použitia akéhokoľvek ďalšieho úložiska nad rámec samotnej matice.





## Gauss-Seidel a SOR Preconditioning

---

- Gauss-Seidel predpodmienenie je zostavene len z prvkov matice:

$$M_{GS} = (D - L)D^{-1}(D - U). \quad (30)$$

- SOR predpodmienenie je zostavene len z prvkov matice:

$$M_{\omega} = \frac{1}{2 - \omega} \left( \frac{1}{\omega} D - L \right) \left( \frac{1}{\omega} D^{-1} \right) \left( \frac{1}{\omega} D - U \right). \quad (31)$$

- Optimálna hodnota parametra  $\omega$ , podobne ako parameter v metóde SOR, zníži počet iterácií.

# Cholesky Preconditioning

- Založene na Choleskyho faktorizácii matice A:

```
for  $k = 0, 1, \dots, n - 1$   
  for  $i = 0, 1, \dots, k - 1$   
     $h_{ki} = \left( a_{ki} - \sum_{j=0}^{i-1} h_{ij} * h_{kj} \right) / h_{ii}$   
  end  
   $h_{kk} = \sqrt{a_{kk} - \sum_{j=0}^{k-1} h_{kj}^2}$   
end
```

V tomto algoritme  $\sum_{j=0}^{-1}() = 0$  a  $h^{00} = \sqrt{a_{00}}$ .



# LU Preconditioning

---

- Založene na LU rozklade matice A:

```
for  $k = 2, \dots, n$   
  for  $k = 1, \dots, i - 1$   
     $a_{ik} = a_{ik} / a_{kk}$   
    for  $j = k + 1, \dots, n$   
       $a_{ij} = a_{ij} - a_{ik} * a_{k,j}$   
    end  
  end  
end
```



## Incomplete LU Preconditioning

- Založene na LU rozklade riedkej matice A:

```
for  $k = 2, \dots, n$   
  for  $k = 1, \dots, i - 1$  a  $if(i, k) \in nnz(A)$   
     $a_{ik} = a_{ik} / a_{kk}$   
    for  $j = k + 1, \dots, n$  a  $if(i, k) \in nnz(A)$   
       $a_{ij} = a_{ij} - a_{ik} * a_{k,j}$   
    end  
  end  
end
```



# Metóda združených gradientov. Conjugate Gradient method.



## Preconditioned Conjugate Gradient (PCG)

- Pôvodná verzia algoritmu CG ktorá funguje pre *SPD* maticu  $A$

$$p^{(0)} = r^{(0)} = b - Ax^{(0)} \quad (32)$$

pre  $i = 1, 2, \dots$  platia nasledujúce vzťahy

$$\alpha_{i-1} = \frac{(r^{(i-1)}, r^{(i-1)})}{(Ap^{(i-1)}, p^{(i-1)})}, \quad (33)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1}p^{(i-1)}, \quad (34)$$

$$r^{(i)} = r^{(i-1)} - \alpha_{i-1}Ap^{(i-1)}, \quad (35)$$

$$\beta_{i-1} = \frac{(r^{(i)}, r^{(i)})}{(r^{(i-1)}, r^{(i-1)})}, \quad (36)$$

$$p^{(i)} = r^{(i)} + \beta_{i-1}p^{(i-1)}, \quad (37)$$

## Preconditioned Conjugate Gradient (PCG)

---

- Ak je  $M$  k dispozícii vo forme napr. Choleského faktorizácie

$$M = LL^T \quad (38)$$

- potom jednoduchým spôsobom, ako zachovať symetriu, je použiť "rozdelenie" predkontácie (3), čím získame symetrickú pozitívne definitnú maticu,

$$L^{-1}AL^{-T}u = L^{-1}b, \quad x = L^{-T}u. \quad (39)$$

## Preconditioned Conjugate Gradient (PCG)

---

- Nie je však potrebné, pre SDP maticu, rozdeliť podmienenie týmto spôsobom, aby sa zachovala symetria. Pre  $M$ -skalárny súčin je  $M^{-1}A$  je samoadjungovaný

$$(x, y)_M = (Mx, y) = (x, My) \quad (40)$$

$$(M^{-1}Ax, y)_M = (Ax, y) = (x, Ay) = (x, M(M^{-1}A)y) = (x, M^{-1}Ay)_M \quad (41)$$

- Preto je možné nahradiť euklidovský skalárny súčin za konjugovaný  $M$  skalárny súčinom.



## Preconditioned Conjugate Gradient (PCG)

- CG prepíše pre tento nový skalarný súčin. Pre jednoduchosť zápisu označíme pôvodné rezíduum  $r^{(j)} = b - Ax^{(j)}$  a predpormienené rezíduum  $z^{(j)} = M^{-1}r^{(j)}$  získame nasledujúcu postupnosť operácií

$$\alpha_{i-1} = \frac{(z^{(i-1)}, z^{(i-1)})_M}{(M^{-1}Ap^{(i-1)}, p^{(i-1)})_M}, \quad (42)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1}p^{(i-1)}, \quad (43)$$

$$r^{(i)} = r^{(i-1)} - \alpha_{i-1}Ap^{(i-1)}, \quad z^{(i)} = M^{-1}r^{(i)}, \quad (44)$$

$$\beta_{i-1} = \frac{(z^{(i)}, z^{(i)})_M}{(z^{(i-1)}, z^{(i-1)})_M}, \quad (45)$$

$$p^{(i)} = z^{(i)} + \beta_{i-1}p^{(i-1)}, \quad (46)$$

## Preconditioned Conjugate Gradient (PCG)

- Predpodmienenu verziu CG môžeme potom zapísať

$$r^{(0)} = b - Ax^{(0)}, z^{(0)} = M^{-1}r^{(0)}, p^{(0)} = z^{(0)} \quad (47)$$

pre  $i = 1, 2, \dots$  platia nasledujúce vzťahy

$$\alpha_{i-1} = \frac{(r^{(i-1)}, z^{(i-1)})}{(Ap^{(i-1)}, p^{(i-1)})}, \quad (48)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1}p^{(i-1)}, \quad (49)$$

$$r^{(i)} = r^{(i-1)} - \alpha_{i-1}Ap^{(i-1)}, \quad (50)$$

$$z^{(i)} = M^{-1}r^{(i)}, \quad (51)$$

$$\beta_{i-1} = \frac{(r^{(i)}, z^{(i)})}{(r^{(i-1)}, z^{(i-1)})}, \quad (52)$$

$$p^{(i)} = z^{(i)} + \beta_{i-1}p^{(i-1)}, \quad (53)$$

## Preconditioned Conjugate Gradient (PCG)

- V prípade praveho predpodmienenia  $AM^{-1}$  prepíšeme CG podľa (2)

$$\alpha_{i-1} = \frac{(r^{(i-1)}, r^{(i-1)})_{M^{-1}}}{(AM^{-1}p^{(i-1)}, p^{(i-1)})_{M^{-1}}}, \quad (54)$$

$$u^{(i)} = u^{(i-1)} + \alpha_{i-1}p^{(i-1)}, \quad (55)$$

$$r^{(i)} = r^{(i-1)} - \alpha_{i-1}Ap^{(i-1)}, \quad (56)$$

$$\beta_{i-1} = \frac{(r^{(i)}, r^{(i)})_{M^{-1}}}{(r^{(i-1)}, r^{(i-1)})_{M^{-1}}}, \quad (57)$$

$$p^{(i)} = r^{(i)} + \beta_{i-1}p^{(i-1)}, \quad (58)$$

kde  $x = M^{-1}u$ .

## Preconditioned Conjugate Gradient (PCG)

- Vektor  $u$  ale nie je nikde potrebný preto vieme prepísať
$$x^{(i)} = x^{(i-1)} + \alpha_{i-1} M^{-1} p^{(i-1)}.$$
- Nahradíme  $q^{(i)} = M^{-1} p^{(i)}$  a  $z^{(i)} = M^{-1} r^{(i)}.$

$$\alpha_{i-1} = \frac{(z^{(i-1)}, r^{(i-1)})}{(Aq^{(i-1)}, q^{(i-1)})}, \quad (59)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1} q^{(i-1)}, \quad (60)$$

$$r^{(i)} = r^{(i-1)} - \alpha_{i-1} Aq^{(i-1)}, \quad z^{(i)} = M^{-1} r^{(i)}, \quad (61)$$

$$\beta_{i-1} = \frac{(z^{(i)}, r^{(i)})}{(z^{(i-1)}, r^{(i-1)})}, \quad (62)$$

$$q^{(i)} = z^{(i)} + \beta_{i-1} q^{(i-1)}, \quad (63)$$

- Ľavo predpodmienený CG algoritmus s  $M$ -skalárnym súčinom je matematicky ekvivalentný v pravo predpodmienenému algoritmu CG s  $M^{-1}$ -skalárnym súčinom.

## Preconditioned Conjugate Gradient (PCG)

---

- V prípade rozdeleného predpodmienenia môžeme napísať

$$\hat{p}^{(i)} = L^T p^{(i)}, \quad (64)$$

$$u^{(i)} = L^T x^{(i)}, \quad (65)$$

$$\hat{r}^{(i)} = L^T z^{(i)} = L^{-1} r^{(i)}, \quad (66)$$

$$\hat{A} = L^{-1} A L^{-T}. \quad (67)$$

## Preconditioned Conjugate Gradient (PCG)

- Kroky CG algoritmu, ktoré riešia  $\hat{A}u = L^{-1}b$ , vieme pre nové premenné napísať

$$\alpha_{i-1} = \frac{(\hat{r}^{(i-1)}, \hat{r}^{(i-1)})}{(\hat{A}\hat{p}^{(i-1)}, \hat{p}^{(i-1)})}, \quad (68)$$

$$u^{(i)} = u^{(i-1)} + \alpha_{i-1}\hat{p}^{(i-1)}, \quad (69)$$

$$\hat{r}^{(i)} = \hat{r}^{(i-1)} - \alpha_{i-1}\hat{A}\hat{p}^{(i-1)}, \quad (70)$$

$$\beta_{i-1} = \frac{(\hat{r}^{(i)}, \hat{r}^{(i)})}{(\hat{r}^{(i-1)}, \hat{r}^{(i-1)})}, \quad (71)$$

$$\hat{p}^{(i)} = \hat{r}^{(i)} + \beta_{i-1}\hat{p}^{(i-1)}, \quad (72)$$

kde  $u = L^T x$ .

## Preconditioned Conjugate Gradient (PCG)

- Rozdelene predpodmienenu verziu CG môžeme potom zapísať

$$r^{(0)} = b - Ax^{(0)}, \hat{r}^{(0)} = L^{-1}r^{(0)}, p^{(0)} = L^{-T}\hat{r}^{(0)} \quad (73)$$

pre  $i = 1, 2, \dots$  platia nasledujúce vzťahy

$$\alpha_{i-1} = \frac{(\hat{r}^{(i-1)}, \hat{r}^{(i-1)})}{(Ap^{(i-1)}, p^{(i-1)})}, \quad (74)$$

$$x^{(i)} = x^{(i-1)} + \alpha_{i-1}p^{(i-1)}, \quad (75)$$

$$\hat{r}^{(i)} = \hat{r}^{(i-1)} - \alpha_{i-1}L^{-1}Ap^{(i-1)}, \quad (76)$$

$$\beta_{i-1} = \frac{(\hat{r}^{(i)}, \hat{r}^{(i)})}{(\hat{r}^{(i-1)}, \hat{r}^{(i-1)})}, \quad (77)$$

$$p^{(i)} = L^{-T}\hat{r}^{(i)} + \beta_{i-1}p^{(i-1)}, \quad (78)$$